基于多层感知机的二维变分自适应网格预测与数值实验

作者：_____ 学号：_____ 课程：机器学习课程设计

摘要：本文研究固定拓扑二维变分网格的参数化预测。针对物理节点预测转为优化初值时的误差，分离网络输出、几何退缩和离散坐标往返。精确教师物理网格的往返误差均值为 6.06%，解释了物理预测误差由 2.19% 增至 6.28% 的现象。复用 200 个真实教师实例，以相同小型 MLP 改为监督计算节点位移，并与物理预测、训练集最近邻、两种传统 Armijo 策略比较。30 个测试实例中，Q 模型初始化物理误差为 2.15%，精修后为 6.06e-05，相对规则初值基线加速 1.82 倍。达到共同阈值的方法中，Q-MLP+ 精修平均耗时最短。Q-MLP 耗时为 1NN 的 0.608 倍、为传统沿用步长方法的 0.685 倍。

关键词：变分网格；多层感知机；计算坐标；插值误差；初值预测

1 引言

变分自适应网格通过优化节点坐标，使固定数量的节点响应给定度量。传统方法每次从规则网格开始时，重复相近参数场的优化可能产生可利用的冗余。监督学习可近似参数到参考终点的映射，但网络输出必须与数值求解器的状态语义一致。若仅比较物理图形而不检查状态转换，误差与效率可能被误判。

本文选择固定方形区域和四参数高斯度量，以已有变分求解器产生教师。已有网格学习研究表明学习网格移动是可行方向 [2]，本课程实验采用可复现的小型全连接网络，考察坐标表示、插值和简单对照对结果的影响。研究问题是：物理预测误差为何在接入求解器后增大；直接计算坐标监督能否改善；相对于简单传统方法是否仍有实际收益。

2 变分问题与坐标接口

区域为 $[0,1]^2$，每轴 12 个方格，共 169 个节点、121 个内部节点及 288 个三角形。初始物理网格 X_0 与规则参考网格 Q_0 数值相同，计算状态 Q 与重建物理网格 X 含义不同。度量在初始单元中心冻结：

$$M_\mu(x,y)=\left[1+A\exp\left(-\frac{(x-c_x)^2+(y-c_y)^2}{\sigma^2}\right)\right]I_2.$$

设 $J_K=B_K(Q)E_K(X_0)^{-1}$，采用冻结物理网格上的离散 Winslow 能量 [1]：

$$I_h(Q;\mu)=\sum_K |K(X_0)|\ \mathrm{tr}\left(J_K M_K^{-1}J_K^T\right).$$

本实现省略常数因子 1/2。梯度对 Q 求导，边界梯度为零。传统教师求得 Q_T 后，以分片线性逆映射在参考节点处求值得到 $X_T=R(Q_T)$。所有能量比较均使用相应计算状态，物理节点不能直接送入能量接口。

3 离散坐标往返的误差诊断

对物理预测 P，原流程先沿 $P - X_0$ 作几何退缩得到 P_{safe}，再插值得到计算初值 $C(P_{safe})$，最后重建为 $R(C(P_{safe}))$。R 与 C 在不同三角剖分上重新采样，其离散组合一般不是恒等算子。通过精确教师输入可将此误差与网络拟合能力分离。

统一使用内部节点移动量 $D_T = \|X_T - X_0\|_{\mathcal{I}}$ 作分母，定义 $e_X = \|X - X_T\|_{\mathcal{I}}/D_T$。计算坐标往返误差另以 $\|Q_T - Q_0\|_{\mathcal{I}}$ 归一化。

量	测试均值/%
原始物理预测误差	2.195
仅几何退缩后的误差	2.195
往返后的预测误差	6.280
精确教师物理网格的往返误差	6.060
教师计算坐标的往返误差	6.062
预测往返引入的变化量	6.189

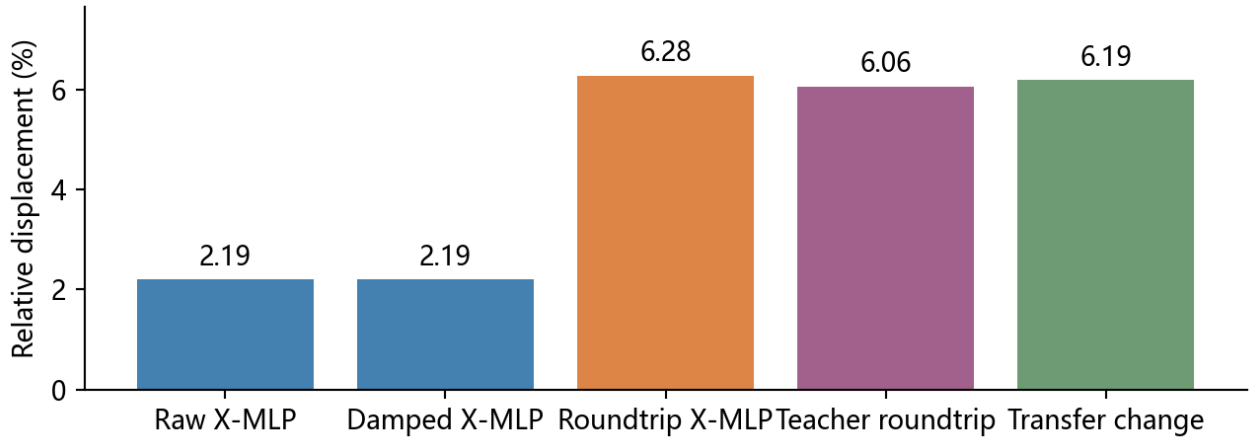


图 1　测试集误差分解。最后一栏为往返引入的变化量，不能与原始误差直接相加。

测试及展示共 33 个实例均未触发物理位移退缩，原始与仅退缩误差完全相同。教师自身也出现约 6.06% 的往返误差，表明额外误差主要来自离散插值。原始 2.19% 的物理预测仍是网络拟合精度的有效量；6.28% 评价的是接入求解器后的物理初值。

令 $a = (P_{safe} - X_T)/D_T$、$b = (R(C(P_{safe})) - P_{safe})/D_T$，有

$$\|a + b\|^2 = \|a\|^2 + \|b\|^2 + 2a^T b.$$

逐实例等式残差均值为 3.97e-19，交叉项均值为-4.893e-04。该向量关系解释为何不能以两种平均误差之差代替插值变化量。教师状态与往返状态的能量均值分别为 1.34915424 和 1.34995801；往返状态仍合法，但不再等于教师终点。

4 数据、学习与比较方法

复用 200 个随机参数教师及 3 个预先固定展示实例，不增加教师求解。参数范围为 $c_x, c_y \in [0.30, 0.70]$、$A \in [2, 8]$、$\sigma \in [0.18, 0.30]$。随机实例整体划分为 140 个训练、30 个验证、30 个测试；展示参数不参与训练和模型选择。

X 模型学习内部 $\Delta X = X_T - X_0$；Q 模型学习内部 $\Delta Q = Q_T - Q_0$。两者均采用 $4 \to 64 \to 64 \to 242$、Tanh、20210 个参数，输入按训练集均值及标准差归一化，标签除以各自训练集位移分量全局 RMS。损失为归一化分量 MSE：

$$L(\theta) = \frac{1}{242N} \sum_{j=1}^{N} \left\| f_\theta(\widetilde{\mu}_j) - \frac{(\Delta Q_T)_j}{s_Q} \right\|_2^2 .$$

Adam 学习率 0.001、权重衰减 10^{-6}、批量 32，最多 2600 轮；验证连续 200 轮无改善即停止，取最佳验证权重。主种子固定 20261021，辅助种子 20261022 只用于波动检查。输入统计与输出缩放均不读取测试标签。Q 预测沿 Q_0 到预测状态退缩，检查 Q 及 R(Q) 有限、边界固定、位于区域内、面积大于 10^{-10}，失败则回退 Q0。

Q 训练种子	最佳轮次	验证坐标 MSE	测试物理误差/%	训练时间/s
20261021	2591	7.007e-07	2.147	26.10
20261022	2567	8.367e-07	2.110	25.89

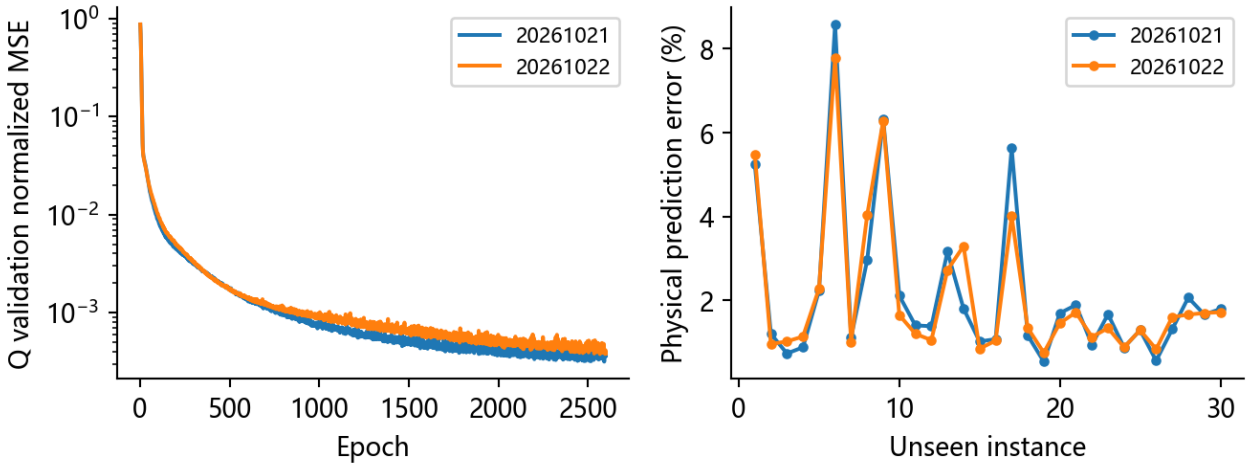


图 2　两个固定种子的验证曲线与测试误差。主种子预先固定，不按测试结果选择。

比较方法为：B0 规则初值、每轮从 1 提议 Armijo；B1 原 X 模型经坐标转换后精修；B2 直接 Q 模型后精修；B3 标准化参数空间中训练集 1 近邻的 Q 教师初值后精修；B4 规则初值、下一轮沿用上次接受步长。B3 只检索 140 个训练教师，不接触验证或测试教师。B4 步长限定在 $[10^{-12}, 1]$，过小则恢复默认提议。

所有方法使用相同冻结度量、边界、Armijo 系数 10^{-4}、退缩因子 1/2、绝对梯度阈值 10^{-5}、2200 接受迭代与 30000 能量评价上限。B0 至 B3 共用原求解器，B4 仅改变步长提议策略。物理预测原模型和最佳权重保持不变。

5 三个代表性数值算例

5.1 中心局部加密

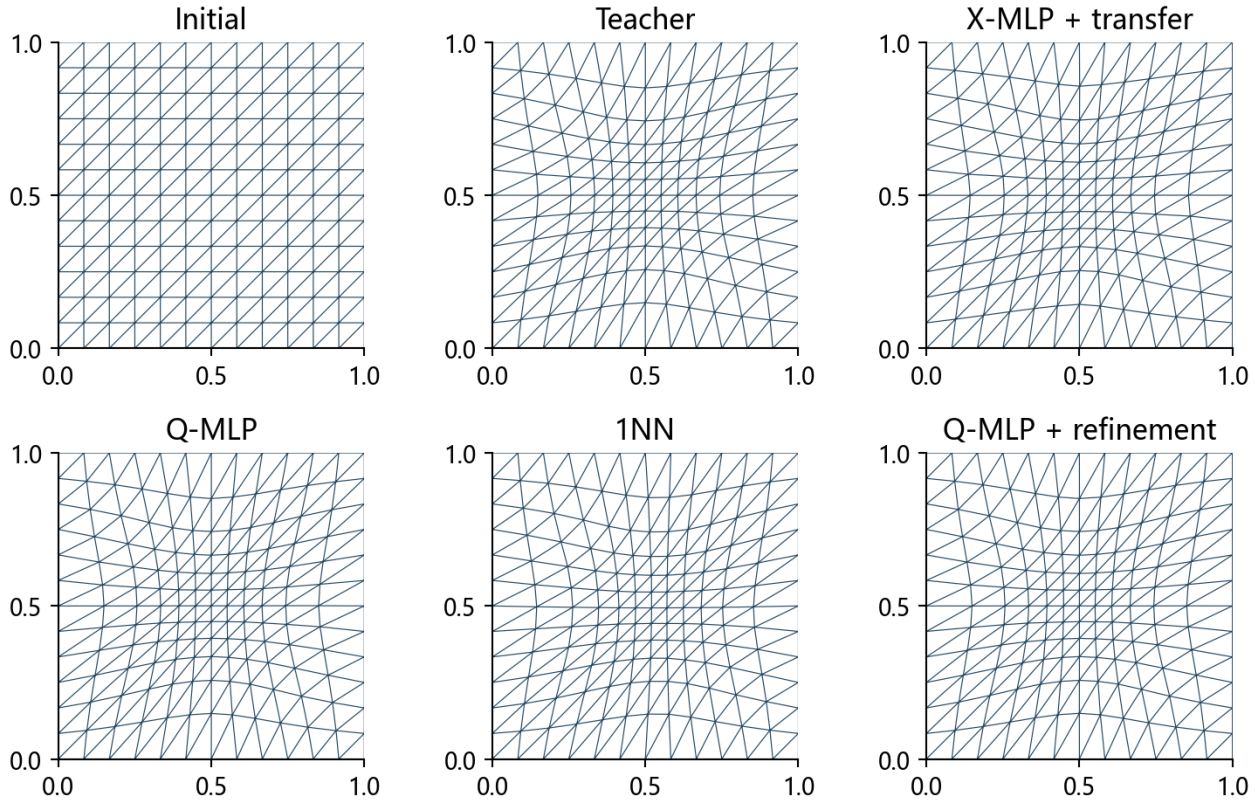


图 3　中心加密六状态比较。所有网格使用相同节点编号、连接和坐标范围。

参数为 $\mu = (0.50, 0.50, 5.0, 0.24)$。X 模型转换后误差为 6.516%，Q 模型重建误差为 0.565%，最近邻误差为 18.297%。Q 模型精修后误差为 6.97e-05，接受迭代 144 次，在线平均 0.8537 秒。

图中比较初始、教师、X 模型转换后、Q 模型、最近邻与 Q 模型精修后的物理网格。直接 Q 监督保留计算状态的含义；物理输出仍由原重建函数产生，因此图形与精修初值对应同一状态。局部节点聚集只是可视化依据，精度取全部内部节点的归一化误差。

算例	X 初始化/%	Q 初始化/%	1NN 初始化/%	Q 精修误差
center	6.516	0.565	18.297	6.97e-05
shifted	6.267	0.936	18.703	1.71e-05
strength	7.069	1.003	28.027	7.88e-05

三个算例分别检验局部峰值位于中心、峰值偏移、强度及宽度改变，均位于给定参数区间内。展示实例不单独训练网络或改变阈值。各方法完整节点数组、初始及最终 Q、最小面积、能量和逐迭代历史随实验保存。

5.2 偏心与较强局部加密

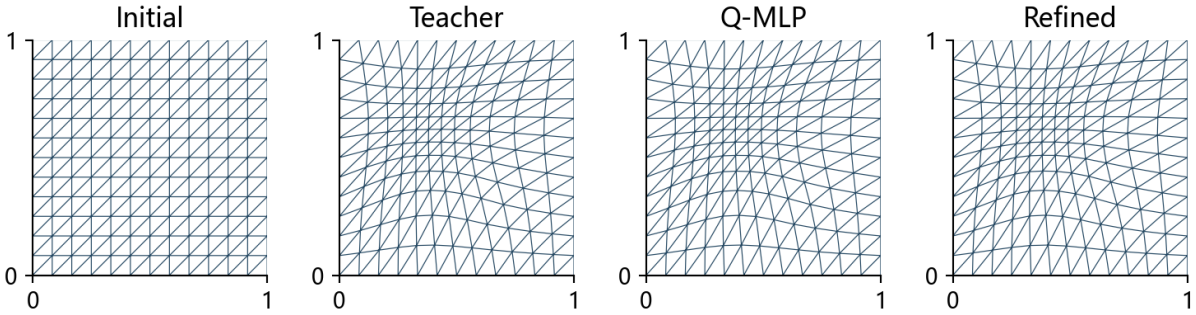


图 4　偏心局部加密的初始、教师、Q 预测与精修网格。

参数为 $\mu = (0.36, 0.64, 5.0, 0.24)$。X 模型转换后误差为 6.267%，Q 模型重建误差为 0.936%，最近邻误差为 18.703%。Q 模型精修后误差为 1.71e-05，接受迭代 211 次，在线平均 0.9585 秒。

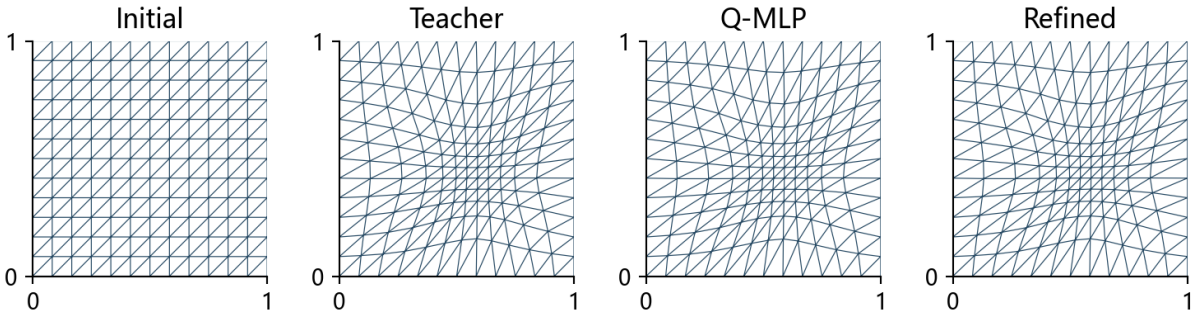


图 5　较强、较窄高斯度量的初始、教师、Q 预测与精修网格。

参数为 $\mu = (0.58, 0.43, 7.5, 0.19)$。X 模型转换后误差为 7.069%，Q 模型重建误差为 1.003%，最近邻误差为 28.027%。Q 模型精修后误差为 7.88e-05，接受迭代 165 次，在线平均 0.8477 秒。

6 独立测试的精度与计算成本

以下为 30 个测试实例均值。初始能量相对差为 $(I_h(Q) - I_h(Q_T))/|I_h(Q_T)|$。

所有预测误差均评价实际进入精修的物理网格 R(Q)，B1 原始物理预测误差另列于诊断。B4 从规则网格出发，因而初始化误差为 1。

方法	初始化误差/%	最终误差	初始能量相对差	收敛数
B0	100.000	0.00e+00	6.40e-02	30/30
B1	6.280	4.24e-05	6.45e-04	30/30
B2	2.147	6.06e-05	8.85e-05	30/30
B3	23.416	5.66e-05	4.52e-03	30/30
B4	100.000	2.74e-05	6.40e-02	30/30

方法	接受迭代	能量评价	回溯次数	在线时间/s	相对 B0 加速
B0	345.0	1296.9	963.9	1.0046	1.00
B1	205.7	786.6	580.0	0.5744	1.75
B2	193.3	739.8	545.5	0.5532	1.82
B3	312.0	1182.0	870.1	0.9105	1.10
B4	389.6	392.7	3.0	0.8078	1.24

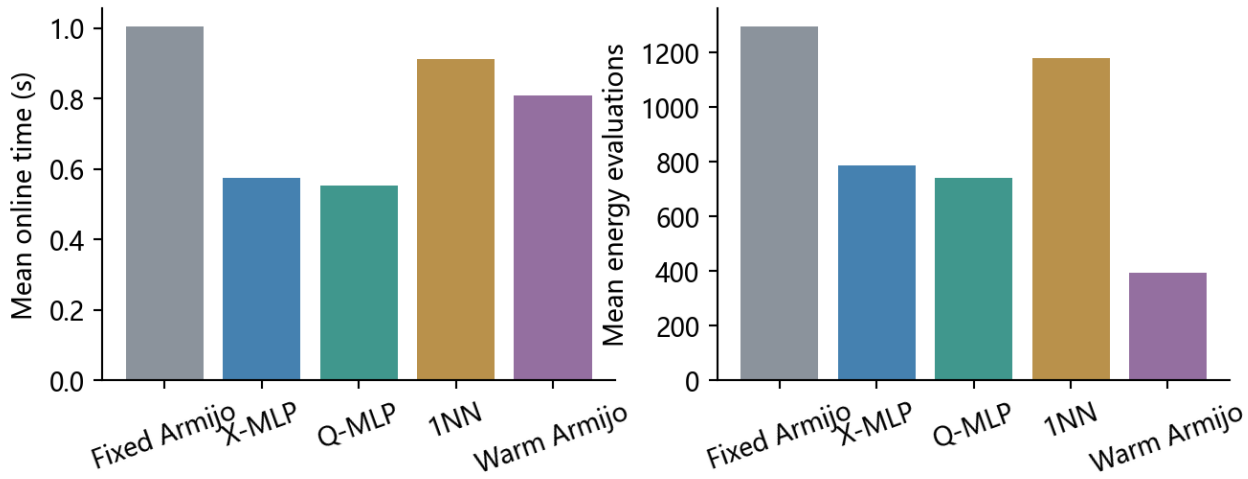


图 6　五种方法完整在线时间与能量评价次数。

模型和最近邻字典在计时前预加载，CPU 单线程，每实例每方法重复三次，按实例与重复次数交替正反执行顺序。计时从问题对象建立开始，包含参数归一化、推理或近邻检索、几何检查、重建及精修；不含磁盘读写、加载、指标计算和训练。timings.csv 保存 495 次运行，metrics.csv 保存 165 组状态与同一实例三次耗时的样本标准差。表中均值基于全部 30 个测试参数，不选择速度较快的个例。

直接计算坐标监督使初始化物理误差由 6.28% 降至 2.15%，完整在线流程相对 B0 加速 1.82 倍。达到共同阈值的方法中，Q-MLP+ 精修平均耗时最短。Q-MLP 耗时为 1NN 的 0.608 倍、为传统沿用步长方法的 0.685 倍。

本次共 165 组最终状态中 165 组几何合法，未收敛组数 0。B1 至 B3 初始化最小退缩系数为 1.000。成功率与最终梯度均保存，不用未达精度的终止时间证明加速。能量评价数反映算法工作量，在线时间还包含重建等实际开销，二者不能互相替代。

7 讨论与结论

7.1 坐标表示与使用价值

精确教师输入的往返误差直接证明：物理坐标到计算坐标的离散转换会改变已经正确的终点，第二轮增加的误差主要由此产生。直接监督 Q 使用现有教师中已保存的状态，避免了多余的 C/R 组合，也使网络输出与能量梯度变量一致。X 模型原始误差仍应独立报告，不能将其转换后误差解释为训练失败。

直接计算坐标监督使初始化物理误差由 6.28% 降至 2.15%，完整在线流程相对 B0 加速 1.82 倍。达到共同阈值的方法中，Q-MLP+ 精修平均耗时最短。Q-MLP 耗时为 1NN 的 0.608 倍、为传统沿用步长方法的 0.685 倍。

Q 模型相对原 X 流程的在线均值缩短 3.68%，属于小幅改善，三次重复不能据此宣称稳定显著领先。Q 重建误差 2.15% 与原始 X 预测 2.19% 接近，主要改进是避免坐标往返，不是网络拟合精度数量级提升。沿用步长仅需 392.7 次能量评价，但接受迭代为 389.6 次，Q 精修为 193.3 次；每次接受还需要物理重建，因此评价数更少没有转化为最短在线时间。

课程设计宜以直接计算坐标预测为主线，并保留最近邻和沿用步长对照。其价值由预测精度、达到同一停止阈值的在线成本与离线摊销共同界定。

最近邻不需要拟合网络，因此是衡量小数据参数回归必要性的直接对照。沿用上次接受步长不需要教师数据，其收益来自减少回溯，不能归为初值预测收益。两类对照分别回答“学习是否优于简单查找”和“收益是否也可由廉价求解策略获得”。本实验据实比较完整在线流程，不将模型推理时间单独作为最终加速。

7.2 离线成本与限制

已有 203 个教师求解累计 227.38 秒，主 Q 模型训练 26.10 秒。若这些教师为新任务专门产生，以 B0 与 B2 本次在线均值差粗算，摊平教师与主训练成本约需 562 次同分布调用。若教师已供其他任务使用，只需计入新增训练成本。辅助种子的训练不属于主模型部署所需成本。

实验限于固定拓扑、分辨率、单高斯冻结度量和参数区间；未测跨分辨率、复杂边界、分布外或 PDE 解误差。几何合法率和达到教师精度不能直接等同于 PDE 精度改善。计时依赖本机负载，三次重复用于记录同一实例的波动；测试实例间的标准差另保存在 aggregate.csv。网页构建与资源一致性检查不替代浏览器视觉与键盘验收，实际状态见 README。

7.3 结论

本文通过教师往返实验解释物理预测接入求解器后的误差，使用同规模 Q-MLP 完成了无需坐标往返的状态预测，并在未见参数与三个代表算例上比较五种方法。核心结论是选择与优化变量一致的监督表示，并以最近邻及传统步长策略界定机器学习收益。该结果支持在当前参数族内进行可复现的课程比较实验。

参考文献

[1] Huang W., Kamenski L., Russell R. D. A comparative numerical study of meshing functionals for variational mesh adaptation. Journal of Mathematics Study, 2015, 48(2):168–186. DOI:10.4208/jms.v48n2.15.04.

[2] Song W., Zhang M., Wallwork J. G., et al. M2N: Mesh Movement Networks for PDE Solvers. Advances in Neural Information Processing Systems, 35, 2022.